

Os Princípios da Teoria de Aprendizado Profundo

O autor aborda o contexto atual em que **à teoria do aprendizado profundo** se encontra, no que diz respeito ao desenvolvimento das Redes Neurais Profundas (DNN), já que a mesma é considerada uma ferramenta poderosa da inteligência artificial (IA), permitindo que sistemas computacionais realizem tarefas complexas. Apesar do sucesso prático da DNN, ainda hoje existe uma desconexão entre a teoria e a prática, dessa forma, há a necessidade de uma melhor compreensão teórica desses modelos. Uma das alternativas de superar esse desafio é tomar como exemplo o campo da física teórica, que muitas vezes explicam o comportamento macroscópico de sistemas complexos a partir de princípios microscópicos, como é o caso do estudo da termodinâmica, no entanto, deve existir um equilíbrio entre a precisão preditiva e a tratabilidade matemática.

Os problemas enfrentados na compreensão teórica da DNN incluem a complexidade da série de Taylor (aproximador de funções), a aleatoriedade na inicialização dos parâmetros e a complexidade do algoritmo de aprendizagem, de onde se propõem soluções que envolvem focar na estrutura específica das redes neurais, desenvolver métodos analíticos específicos e investigar a dinâmica do algoritmo de aprendizagem. Isso permite lidar com a complexidade da série de Taylor, considerar todas as variáveis interdependentes no treinamento da rede e compreender a evolução dos parâmetros ao longo do tempo. Ao fazer isso, podemos obter uma compreensão mais precisa e acessível das redes neurais profundas.

Um dos primeiros embasamentos teóricos da DNN abordado diz respeito ao princípio de dispersão, que introduz o conceito de considerar não apenas o limite de largura, mas também a profundidade em redes neurais. Isso ajuda a compreender por que uma abordagem de uma rede hipotética com largura infinita, embora possa resolver problemas técnicos de forma mais simples, não é realista para a aprendizagem de representações significativas. Entretanto, uma maneira de contornar essa abstração é aplicar **a teoria da perturbação** que considera uma expansão de $1/n$, onde n é a largura da rede, para obter uma descrição mais realista e tratável da CNN. Isso leva a uma distribuição quase gaussiana de ordem $1/n$. Essas ideias e teorias fundamentais fornecem uma base para a compreensão da teoria do aprendizado profundo. No entanto, é de fundamental focar também em encontrar uma descrição macroscópica eficaz das DNN's, no sentido de superar os desafios teóricos associados à compreensão desses sistemas complexos, ao invés de se perder em cálculos formais detalhados, **a teoria efetiva** busca uma compreensão intuitiva de entender os padrões ou comportamentos que surgem de maneira natural em sistemas complexos, permitindo insights valiosos sobre o comportamento das redes neurais, além de possibilitar que pesquisadores e praticantes da área de aprendizado profundo desenvolvam uma compreensão mais profunda das redes neurais sem se perder em detalhes matemáticos complicados.

É importante entender e reconhecer que as teorias ainda estão em desenvolvimento e podem não capturar completamente a complexidade das redes neurais profundas. No entanto, esses conceitos oferecem uma base sólida para o avanço do nosso entendimento, e ainda sim se faz necessário um trabalho contínuo para refiná-los de maneira eficaz na prática. Além disso, é importante considerar as implicações éticas e sociais do desenvolvimento de redes neurais profundas e garantir que essas tecnologias sejam utilizadas de forma responsável e ética.